

یادگیری عمیق

مینی پروژه چهارم

نام استاد : دکتر ستوده

نام دانشجو : حمزه قادی

شماره دانشجویی: 9831419


مقدمه

شبکه های GAN یکی از زیباترین ایده های مطرح شده در حوزه یادگیری ماشین در ده سال اخیر میباشد

این شبکه ها- با یادگیری توزیع احتمال داده های ورودی، میتوانند از توزیعی که یادگرفته اند نمونه بسازند (حرف G در GAN اشاره به generative بودن این شبکه ها دارد) ایده کلی آنها بدین صورت است که یک شبکه عصبی به نام Generator با دریافت نویز، نمونه هایی از جنس ورودی میسازد و این نمونه های ساخته شده را به شبکه discriminator میدهد که این شبکه نیز میتواند نمونه واقعی و جعلی را از هم تفکیک کند. در ابتدای فرایند یادگیری، نمونه های Generator به راحتی توسط discriminator رد میشود اما رفته رفته شبکه Generator قادر به ساخت نمونه هایی بسیار شبیه به توزیع داده هاست این فرایند تا آنجا ادامه میابد که شبکه discriminator قادر به تشخیص نمونه های ساخته شده توسط generator نباشد در این مرحله شبکه Generator توزیع احتمال داده های ورودی را یادگرفته است. از منظری دیگر Generator را میتوان بدیل Encoder در شبکه های Autoencoder دانست همانگونه که encoder ها داده های ورودی را به یک فضای معمولاً با بعد کمتر نگاشت میکنند (که به این فضا latent space میگویند) Generator ها نیز داده های ورودی را به یک فضا با بعد کمتر (که هم بعد با نویز دریافتی Generator است) نگاشت میکنند. در نهایت و پس از فرایند یادگیری (یا همان کردن نگاشت بهینه) میتوان با ارائه یک بردار از این فضا به Generator نمونه ای شبیه به داده های اولیه استفاده شده برای آموزش، دریافت کرد.

هدف


در این پروژه یک شبکه GAN طراحی میشود که با یادگرفتن توزیع داده های MNIST میتواند عکسهای قلابی شبیه به اعداد دستنویس موجود در MNIST بسازد. چون در ساختار این شبکه از لایه های کانولوشنی استفاده شده است به این ساختار DCGAN میگویند. در شکل زیر تعدادی از نمونه های دیتابیس MNIST قابل مشاهده است:



نکات کلی:

در این پروژه از تابع LeakyReLU به عنوان فعالساز استفاده شده است. ضابطه این تابع به صورت زیر است:

$$y = \max(0.1x, x)$$



بهینه ساز مورد استفاده در این پروژه Adam است که رابطه آن به صورت زیر است. این بهینه ساز با ترکیب ایده های بهینه سازهای momentum و RMSprop هم مشکل سقوط در نقاط پست¹ و هم مسئله نوسان را کاهش داده است

¹ Saddle point

For each Parameter w^j

(j subscript dropped for clarity)

$$\nu_t = \beta_1 * \nu_{t-1} - (1 - \beta_1) * g_t$$

$$s_t = \beta_2 * s_{t-1} - (1 - \beta_2) * g_t^2$$

$$\Delta\omega_t = -\eta \frac{\nu_t}{\sqrt{s_t + \epsilon}} * g_t$$

$$\omega_{t+1} = \omega_t + \Delta\omega_t$$

η : Initial Learning rate

g_t : Gradient at time t along ω^j

ν_t : Exponential Average of gradients along ω_j

s_t : Exponential Average of squares of gradients along ω_j

β_1, β_2 : Hyperparameters

BatchNormalization: این لایه ورودی خود را به صورت z-score (یعنی با واریانس یک و میانگین صفر) به عنوان خروجی تحویل

میدهد

Conv2DTranspose: این لایه عملیاتی شبیه به کانولوشون را انجام میدهد و خروجی آن تصویری با ابعاد بزرگتر از تصویر ورودی

است.

همچنین از BinaryCrossEntropy به عنوان تابع هزینه استفاده شده است

(*) فرایند یادگیری این شبکه بسیار زمان گیر بوده و نتایج نهایی پس از 50 تا epoch به دست آمده است احتمالاً صرف وقت و افزایش تعداد epoch ها باعث بهبود تصاویر ساخته شده خواهد شد اما به هرصورت Generator قادر نخواهد بود به تمامی اعضای فضای نويز پاسخ قابل تشخیصی بدهد لذا به منظور مشخص شدن کارایی Generator، پس از آموزش، تعداد زیادی ورودی نويز به آن اعمال شده و بهترین خروجی ها انتخاب شده است..

بخش اول: طراحی شبکه Discriminator

فرایند یادگیری شبکه های Generator و Discriminator به صورت همزمان و در یک حلقه اتفاق می افتد در طی این حلقه Discriminator باید نحوه تشخیص تصاویر جعلی از واقعی را یادبگیرد و Generator نیز باید ساختن تصاویری جعلی ولی مشابه تصاویر دیتاست را بیاموزد. بدیهی است که وظیفه Generator سخت تر است و لذا زمان بیشتری برای یادگیری میطلبد. درحالیکه وظیفه Discriminator به راحتی و حتی توسط یک شبکه عصبی ساده قابل فراگیریست. لذا Discriminator باید به گونه ای طراحی شود که در طی این فرایند طولانی دچار Overfitting نشود بدین منظور در ساختار آن از تعداد قابل ملاحظه ای لایه Dropout استفاده شده است. این لایه با حذف تعدادی از واحدهای لایه قبل از خود، باعث تحریک شبکه به یادگیری بیشتر میشود در عین حال overfitting را نیز کاهش میدهد. از طرفی چون لایه خروجی شبکه discriminator دارای فعال ساز سیگموئید است، امکان اشباع شدن و لذا محو شدگی گرادیان وجود دارد که این امر نیز میتواند ناشی از بزرگ شدن اعداد در فرایند محاسبه گرادیان باشد به منظور کاهش این پدیده، از لایه های BatchNormalization استفاده شده است. این لایه خروجی های لایه قبل از خود را (با فرض گوسی بودن) به حالت نرمال استاندارد (یعنی توزیع نرمال با میانگین صفر و واریانس یک) تبدیل میکند که این امر باعث کوچک شدن اعداد و لذا کاهش پدیده محو شدگی گرادیان میشود.

ساختار شبکه Discriminator:

این شبکه یک عکس 28×28 را دریافت کرده و با عبور آن از لایه های کانولوشنی و فعالساز های غیر خطی و نهایتاً یک لایه با فعال ساز سیگموید، خروجی صفر یا یک را تولید کرده که جعلی یا حقیقی بودن عکس دریافتی را مشخص میکند


ساختار ای شبکه به صورت زیر است:

Model: "discriminator"		
Layer (type)	Output Shape	Param #
=====		
input_1 (InputLayer)	(None, 28, 28, 1)	0
=====		
conv2d_1 (Conv2D)	(None, 14, 14, 64)	1664
=====		
leaky_re_lu_1 (LeakyReLU)	(None, 14, 14, 64)	0
=====		
dropout_1 (Dropout)	(None, 14, 14, 64)	0
=====		
batch_normalization_1 (Batch Normalization)	(None, 14, 14, 64)	256
=====		
conv2d_2 (Conv2D)	(None, 7, 7, 128)	204928
=====		
leaky_re_lu_2 (LeakyReLU)	(None, 7, 7, 128)	0
=====		
dropout_2 (Dropout)	(None, 7, 7, 128)	0
=====		

بخش دوم: طراحی شبکه Generator

شبکه Generator، نویز یونیفرم 256 بعدی را به عنوان ورودی دریافت کرده و خروجی آن باید عکسی مشابه به عکسهای دیتاست مذکور باشد. این شبکه باید نویز ورودی را که یک بردار ستونی 256 بعدی است به یک تصویر 28×28 تبدیل کند بدین منظور ابتدا نویز ورودی از یک لایه Dense با $7 \times 7 \times 256$ واحدی عبور داده شده و خروجی این لایه از یک لایه فعالساز LeakyReLU عبور داده میشود و سپس ابعاد ورودی تغییر میکند از ای مرحله به بعد از لایه Conv2DTranspose به منظور Upsampling استفاده شده است همچنین لایه های Dropout و BatchNormalization نیز به منظور جلوگیری از محو شدن گرادینان و اشباع شدن تابع خروجی به تعداد زیاد استفاده شده است!....

خروجی Generator قبل از آموزش به صورت زیر است...ساختار شبکه نیز در زیر قابل مشاهده است.



Model: "generator"		
Layer (type)	Output Shape	Param #
=====		
input_2 (InputLayer)	(None, 100)	0
dense_2 (Dense)	(None, 12544)	1266944
dropout_3 (Dropout)	(None, 12544)	0
leaky_re_lu_3 (LeakyReLU)	(None, 12544)	0
batch_normalization_3 (Batch Normalization)	(None, 12544)	50176
reshape_1 (Reshape)	(None, 7, 7, 256)	0
conv2d_transpose_1 (Conv2DTr)	(None, 7, 7, 128)	819200
batch_normalization_4 (Batch Normalization)	(None, 7, 7, 128)	512
dropout_4 (Dropout)	(None, 7, 7, 128)	0
leaky_re_lu_4 (LeakyReLU)	(None, 7, 7, 128)	0
conv2d_transpose_2 (Conv2DTr)	(None, 14, 14, 128)	409600
batch_normalization_5 (Batch Normalization)	(None, 14, 14, 128)	512
dropout_5 (Dropout)	(None, 14, 14, 128)	0
leaky_re_lu_5 (LeakyReLU)	(None, 14, 14, 128)	0
conv2d_transpose_3 (Conv2DTr)	(None, 14, 14, 128)	409600
batch_normalization_6 (Batch Normalization)	(None, 14, 14, 128)	512
dropout_6 (Dropout)	(None, 14, 14, 128)	0
leaky_re_lu_6 (LeakyReLU)	(None, 14, 14, 128)	0
conv2d_transpose_4 (Conv2DTr)	(None, 28, 28, 1)	6272
=====		
Total params: 2,963,328		
Trainable params: 2,937,472		
Non-trainable params: 25,856		

بخش سوم : ساختار شبکه GAN

این شبکه یک بردار نویز 256 بعدی را دریافت کرده و با عبور آن از Generator یک تصویر $28*28*1$ میسازد و سپس با اعمال این تصویر به عنوان ورودی Discriminator آنرا اعتبار سنجی میکند و نهایتاً بر اساس آن پارامترهای Generator را آپدیت میکند (در طی این فرایند Discriminator تغییر نمیکند)

ساختار آن به صورت زیر است:

Model: "gan"		
Layer (type)	Output Shape	Param #
=====		
input_3 (InputLayer)	(None, 100)	0
generator (Model)	(None, 28, 28, 1)	2963328
discriminator (Model)	(None, 1)	213633
=====		
Total params: 3,176,961		
Trainable params: 2,937,472		
Non-trainable params: 239,489		

بخش چهارم : آموزش شبکه

به منظور آموزش شبکه از دو حلقه تودرتو استفاده شده است حلقه اول به تعداد epochs اجرا شده و حلقه دوم به تعداد batch های موجود در دیتاست بدین ترتیب از تعداد زیادی از نمونه های موجود در دیتاست و احتمال تکرار بالای یک نمونه، در فرایند آموزش استفاده میشود. در هر بار اجرای حلقه دوم، یک بچ از عکسهای موجود در در دیتاست و یک بچ از عکسهای تولیدی توسط Generator برای آموزش Discriminator و نیز آپدیت generator استفاده میشود.

همانطور که پیشتر گفته شده Generator سعی میکند یک توزیع احتمال مشترک در ابعاد نویز (در فضای نویز) به تصاویر دیتاست نسبت دهد لذا از لحاظ تئوری باید بتواند به هر برداری از فضای نویز (فضایی با ابعاد نویز ورودی که در اینجا یک فضای 256 بعدیست) یک تصویر مناسب نسبت دهد اما لزوما این تصویر معنای خاصی ندارد!...بنابراین به منظور نشان دادن کیفیت Generator تعداد زیادی (16 بار و هر بار 64 ورودی) به generator اعمال شده و بهترین خروجی ها انتخاب شده است.

فرایند یادگیری Generator بسیار طولانی بوده و نتیجه قابل قبول پس از حد اقل 50 epoch و صرف زمانی نزدیک به یک روز و در پلتفرم colab حاصل شده است.

تصاویر زیر پس از 10 تا epoch به دست آمده است:



پس از 50 تا epoch تصاویر حاصله قابل تشخیص تر شده اند

